



Unisport

Máster en Big Data e IA en el Deporte

DETECCIÓN DE TALENTO EN JÓVENES FUTBOLISTAS
(16–19 AÑOS)

INTEGRANTES:
Calviño García, Jacobo

14 de julio de 2026

Índice

1. Introducción y contexto	2
2. Generación y recopilación de datos	2
2.1. Fuente de los datos y herramienta de análisis	2
2.2. Definición de las métricas seleccionadas	3
2.3. Estructura, etiqueta objetivo y almacenamiento	3
3. Exploración y limpieza de datos	4
3.1. Auditoría de calidad y tratamiento	4
3.2. Análisis descriptivo	4
4. Modelado predictivo	7
4.1. Planteamiento y protocolo	7
4.2. Resultados e interpretación	7
5. Evaluación del modelo	8
5.1. Métricas sobre el conjunto de prueba y validación cruzada	8
5.2. Lectura de los errores y umbral de decisión	9
6. Análisis de sensibilidad: tamaño muestral	10
7. Informe final: hallazgos y recomendaciones	11
7.1. Jugadores destacados	11
7.2. Recomendaciones estratégicas	12
8. Conclusiones	12

1. Introducción y contexto

Este informe se elabora desde el rol de analista de datos del departamento de scouting de un club de fútbol profesional. El encargo de la dirección deportiva consiste en construir un sistema de detección de talento para jugadores de entre 16 y 19 años, basado en datos objetivos extraídos de vídeos de partidos y entrenamientos, que sirva de apoyo a la toma de decisiones sobre posibles incorporaciones.

El scouting tradicional se apoya en la observación subjetiva de ojeadores, un método valioso pero expuesto a sesgos: efecto de la edad relativa, sobrevaloración de acciones llamativas y tamaño muestral reducido de observaciones. La analítica de vídeo permite complementar ese criterio experto con indicadores cuantitativos, medidos de forma sistemática y comparable entre jugadores [1].

El trabajo sigue el ciclo completo de un proyecto de ciencia de datos aplicado al deporte: (1) generación y recopilación de datos a partir de vídeo, (2) exploración y limpieza, (3) modelado predictivo, (4) evaluación del modelo, incluyendo un análisis de sensibilidad al tamaño muestral, y (5) comunicación de hallazgos y recomendaciones estratégicas. Todo el análisis es reproducible: el código (Python: `pandas`, `scikit-learn`) está versionado en un repositorio público, y las tablas y figuras de este documento se generan directamente desde los cuadernos de análisis.

2. Generación y recopilación de datos

2.1. Fuente de los datos y herramienta de análisis

Los datos proceden del análisis de vídeos de partidos oficiales de categorías juvenil y sub-19, así como de sesiones de entrenamiento grabadas con cámara táctica panorámica. Se analizó una muestra de 40 jugadores, con un mínimo de cuatro partidos completos y dos sesiones de entrenamiento por jugador, para reducir el efecto del rendimiento puntual de un solo encuentro.

Para el etiquetado y la extracción de eventos se empleó una herramienta de analítica de vídeo con una plantilla de categorías y descriptores comunes para todos los analistas. Siguiendo las buenas prácticas de anotación de vídeo deportivo [2], cada evento se etiquetó con el jugador, el minuto, la zona del campo y el resultado de la acción, y una fracción de los clips fue codificada por dos analistas de forma independiente para verificar la fiabilidad inter-observador. Las variables físicas se obtuvieron mediante tracking óptico semiautomático sobre el propio vídeo.

Dado el carácter académico del trabajo, el conjunto de datos se ha generado mediante simulación estadística calibrada con rangos realistas para esta categoría de edad. Este enfoque tiene además una ventaja metodológica: al conocerse el proceso generador de los

datos, es posible verificar que los métodos de análisis recuperan la estructura verdadera (véase la Sección 4).

2.2. Definición de las métricas seleccionadas

Se seleccionaron ocho parámetros, dentro del rango óptimo de seis a ocho indicadores, cubriendo las dimensiones técnica, física y cognitiva del rendimiento:

- **Precisión de pase (%)**: pases completados sobre intentados; indicador técnico básico de asociación y conservación.
- **Velocidad de reacción (s)**: tiempo medio entre un estímulo (pérdida, pase al espacio) y la primera respuesta motriz, medido fotograma a fotograma. *Menor valor indica mejor rendimiento.*
- **Efectividad en el uno contra uno (%)**: duelos individuales ganados, ofensivos y defensivos.
- **Velocidad de sprint (km/h)**: velocidad punta estimada por tracking óptico.
- **Distancia a alta intensidad (por 90')**: metros por encima de 19,8 km/h normalizados a 90 minutos.
- **Acierto en el regate (%)**: regates intentados con éxito.
- **Recuperaciones (por 90')**: balones recuperados; indicador de anticipación.
- **Índice de toma de decisiones (0–10)**: valoración estructurada mediante rúbrica (elección de pase, orientación corporal, ocupación de espacios), promediada entre observadores.

La elección responde a tres criterios: incluir los tres indicadores clave solicitados por la dirección deportiva; equilibrar las dimensiones técnica, física y cognitiva, dado que la literatura de detección de talento desaconseja perfiles contruidos sobre una sola dimensión; y que todas las métricas sean extraíbles de vídeo con un coste de anotación asumible.

2.3. Estructura, etiqueta objetivo y almacenamiento

Cada fila del conjunto de datos corresponde a un jugador y cada columna a una variable (formato *tidy*), con identificador anonimizado, posición y edad. Como variable objetivo se incorporó una etiqueta binaria de *alto potencial* (prevalencia del 35 %), que en un despliegue real se construiría retrospectivamente a partir del histórico del club (jugadores que llegaron a debutar en filial o primer equipo). Los datos se almacenan en un repositorio versionado, separando el fichero bruto (`data/raw`) del procesado (`data/processed`); en

producción, el tratamiento de datos de menores exigiría seudonimización, acceso restringido y las garantías del RGPD.

3. Exploración y limpieza de datos

3.1. Auditoría de calidad y tratamiento

La auditoría del fichero bruto ($n = 40$) siguió reglas de validación definidas *a priori* (porcentajes en $[0, 100]$, reacción en $[0, 3, 1, 2]$ s, sprint en $[24, 36]$ km/h). Se detectaron dos tipos de incidencias habituales en datos anotados desde vídeo:

- **Valores ausentes** (3 celdas): campos sin registrar por clips inutilizables o ángulos de cámara deficientes.
- **Un valor físicamente imposible**: una velocidad de sprint de 41,2 km/h en el jugador J08, atribuible a un error del tracking óptico (confusión de identidades). Se recodificó como ausente, aplicándole la misma regla que al resto: una única regla, aplicada de forma consistente.

Las celdas ausentes (cuatro tras la recodificación anterior, poco más del 1 % del total) se imputaron con la **mediana de la posición** del jugador: la mediana es robusta frente a valores extremos y la segmentación por demarcación respeta que un defensa y un extremo presentan perfiles distintos en métricas como el regate o las recuperaciones. Se descartó eliminar filas (supondría perder un 10 % de la muestra) e imputar con la mediana global (arrastraría al jugador hacia un perfil promedio ajeno al suyo). Tras la limpieza se verificó programáticamente la ausencia de valores nulos y fuera de rango; todo el proceso es un script reproducible que regenera el fichero limpio desde el bruto.

Cabe señalar que los valores extremos *plausibles* se conservaron: en scouting, los extremos del rendimiento son precisamente el objeto de búsqueda, y eliminarlos por criterios puramente estadísticos destruiría la señal de interés.

3.2. Análisis descriptivo

La Tabla 1 resume los estadísticos de los ocho parámetros tras la limpieza.

Las distribuciones (Figura 1) son aproximadamente simétricas y no muestran anomalías tras la limpieza.

La matriz de correlaciones (Figura 2) muestra que la etiqueta de alto potencial se asocia principalmente con el índice de toma de decisiones ($r = 0,39$), la precisión de pase ($r = 0,36$) y el acierto en el regate ($r = 0,21$), y negativamente con el tiempo de reacción ($r = -0,28$; recuérdese que en esta variable menor es mejor). No se detecta multicolinealidad severa entre predictores.

Tabla 1: Estadísticos descriptivos de los parámetros de rendimiento ($n = 40$).

	Media	Desv. típ.	Mín.	Mediana	Máx.
Precisión de pase (Vel. reacción (s))	0.62	0.07	0.47	0.63	0.75
Efectividad 1v1 (Vel. sprint (km/h))	29.41	1.66	26.09	29.26	33.50
Dist. alta int. ($\times 100$ m/90')	6.91	1.14	5.16	6.77	9.35
Acierto regate (Recuperaciones /90')	6.66	2.16	2.98	6.40	12.00
Toma de decisión (0–10)	6.66	1.10	3.78	6.72	8.52




Figura 1: Distribución de los ocho parámetros de rendimiento ($n = 40$).




Figura 2: Matriz de correlaciones entre parámetros y etiqueta de alto potencial.

La comparación de grupos (Figura 3) confirma el patrón: los jugadores de alto potencial superan al resto en más de 4 puntos porcentuales de precisión de pase y de acierto en el regate, puntúan casi un punto por encima en toma de decisiones (7,2 frente a 6,4) y reaccionan unas 4 centésimas más rápido. En cambio, la efectividad en el uno contra uno apenas difiere entre grupos en esta muestra, un matiz que se retoma en las Secciones 4 y 8.




Figura 3: Métricas clave según grupo de potencial.

4. Modelado predictivo

4.1. Planteamiento y protocolo

El problema se formula como una clasificación binaria supervisada: estimar $P(\text{alto potencial} = 1)$ a partir de los ocho parámetros. Se persigue la probabilidad, y no solo la clase, porque el producto operativo del sistema es un *ranking* de prioridad de seguimiento.

La muestra se dividió en entrenamiento (70 %, $n = 28$) y prueba (30 %, $n = 12$) con estratificación por la variable objetivo, imprescindible con muestras pequeñas para conservar la proporción de clases en ambos conjuntos. Las variables se estandarizaron dentro de un *pipeline* que encadena escalado y modelo, garantizando que toda transformación se aprende exclusivamente del conjunto de entrenamiento (evitando así fuga de información o *leakage*) y que los coeficientes resultantes son comparables entre sí.

Se compararon dos algoritmos: una **regresión logística** (modelo lineal interpretable, adecuado para muestras pequeñas) y un **Random Forest** de 300 árboles (modelo flexible no lineal, incluido como contraste).

4.2. Resultados e interpretación

La regresión logística mostró una brecha moderada entre el acierto en entrenamiento y en prueba (0,82 frente a 0,67), mientras que el Random Forest ajustó perfectamente el entrenamiento (1,00) y cayó en prueba (0,58): un diagnóstico claro de sobreajuste,

coherente con entrenar un modelo flexible con solo 28 observaciones. En el conjunto de prueba la logística supera al Random Forest en todas las métricas, aunque en validación cruzada ambos resultan estadísticamente indistinguibles con esta muestra (Sección 5); la selección de la regresión logística como modelo final se apoya, por tanto, en su menor sobreajuste, en el requisito práctico de interpretabilidad ante la dirección deportiva y en su mejor comportamiento medio en el análisis de sensibilidad de la Sección 6.




Figura 4: Coeficientes estandarizados de la regresión logística.

La lectura de los coeficientes (Figura 4) sitúa como predictores dominantes el índice de toma de decisiones y la precisión de pase, seguidos del acierto en el regate; la velocidad de reacción presenta el signo negativo esperado. Llama la atención que la efectividad en el uno contra uno, pese a tener un peso relevante en el proceso generador de los datos, aporta poco en esta muestra: el ruido muestral con $n = 40$ la ha diluido. La verificación contra los pesos verdaderos de la simulación (correlación de 0,87 entre pesos y coeficientes, con coincidencia de signo en las variables principales) confirma que el modelo recupera la estructura global, e ilustra a la vez una lección metodológica: con pocos datos, los coeficientes individuales de menor magnitud no son interpretables de forma aislada.

El modelo asigna a cada jugador una probabilidad entre 0 y 1, que se utiliza como puntuación para ordenar la lista de seguimiento del departamento: un sistema de priorización de recursos, no una decisión automática de fichaje.

5. Evaluación del modelo

5.1. Métricas sobre el conjunto de prueba y validación cruzada

Con una prevalencia del 35 %, un clasificador trivial que predijera siempre la clase mayoritaria alcanzaría un 0,67 de exactitud en el conjunto de prueba; esa es la línea base

que todo modelo debe superar. La Tabla 2 resume las métricas de ambos modelos sobre el conjunto de prueba y el AUC de la validación cruzada estratificada de cinco particiones, aplicada sobre el *pipeline* completo para evitar fugas de información entre particiones.

Tabla 2: Métricas de evaluación sobre el conjunto de prueba y validación cruzada.

	Reg. logística	Random Forest
Exactitud (accuracy)	0.670000	0.580000
Precisión (precision)	0.500000	0.330000
Sensibilidad (recall)	0.250000	0.250000
F1-score	0.330000	0.290000
AUC-ROC	0.660000	0.560000
AUC-ROC (CV 5-fold)	0.62 ± 0.18	0.64 ± 0.23




Figura 5: Matriz de confusión del modelo final y curvas ROC comparadas.

El AUC admite una interpretación directa: es la probabilidad de que, tomados al azar un talento real y un jugador que no lo es, el modelo puntúe más alto al primero. El valor obtenido (0,66 en prueba; $0,62 \pm 0,18$ en validación cruzada, intervalo que contiene al primero y confirma la coherencia interna de la evaluación) indica una capacidad discriminante moderada, superior al azar pero con claro margen de mejora. La desviación entre particiones se reporta deliberadamente: es la cuantificación honesta de la incertidumbre asociada a evaluar con 40 jugadores, y motiva el análisis de la Sección 6.

5.2. Lectura de los errores y umbral de decisión

La matriz de confusión (Figura 5) muestra que, de los 4 talentos reales del conjunto de prueba, el modelo con el umbral estándar de 0,5 identificó solo 1 (sensibilidad del 25 %), con 3 falsos negativos y un único falso positivo. En scouting los dos tipos de error tienen costes muy asimétricos: un falso positivo implica horas de seguimiento adicional sobre

un jugador que no destacará; un falso negativo supone descartar prematuramente a un futuro profesional, que puede acabar fichando un club rival. Por ello debe priorizarse la sensibilidad.

Esta asimetría tiene una consecuencia operativa: el umbral de 0,5 es arbitrario. El análisis de umbrales realizado muestra que operar en 0,30 duplica la sensibilidad (del 25 % al 50 %) manteniendo la precisión en el 50 %, a cambio de ampliar de 2 a 4 los jugadores señalados para seguimiento: un intercambio claramente favorable siempre que el club disponga de capacidad de observación. La elección del umbral es, en definitiva, una decisión de negocio informada por los datos, no un parámetro estadístico.

Entre las limitaciones cabe señalar el posible sesgo de la etiqueta retrospectiva (debutar en el filial depende también de factores no medidos: lesiones, oportunidades, decisiones de entrenadores) y la ausencia de variables contextuales como el nivel del rival.

6. Análisis de sensibilidad: tamaño muestral

Para dimensionar el sistema y cuantificar el valor de ampliar la base de datos, se estudió la relación entre el número de jugadores y el rendimiento del modelo. Se generaron conjuntos de datos de tamaño creciente (de 40 a 1 280 jugadores, con cinco réplicas por tamaño para promediar la variabilidad de la simulación) y se evaluó cada modelo mediante validación cruzada (Figura 6). Como referencia, se estimó el techo de rendimiento alcanzable entrenando con una muestra muy grande ($n = 20\,000$), que resultó en un AUC de 0,85: la parte del éxito deportivo que es intrínsecamente impredecible desde estas métricas impide superar ese valor por muchos datos que se acumulen.




Figura 6: Curva de aprendizaje: AUC (validación cruzada) frente al número de jugadores. Barras de error: desviación típica entre réplicas.

Tres conclusiones se desprenden de la curva. Primera: con los 40 jugadores actuales el sistema deja rendimiento sobre la mesa (AUC medio de 0,77 entre réplicas, con gran variabilidad); al ampliar la muestra hasta unos 150–300 jugadores el AUC asciende a $\approx 0,84$ – $0,85$, prácticamente el techo estimado, lo que cuantifica el retorno esperado de invertir en más anotación de vídeo. Segunda: la mejora presenta rendimientos decrecientes, de modo que el grueso de la ganancia se obtiene en las primeras ampliaciones. Tercera: el Random Forest recorta distancia al crecer la muestra pero no llega a alcanzar a la regresión logística ni con 1 280 jugadores, confirmando que su peor resultado inicial se debía principalmente a la escasez de datos y que, en este problema de estructura esencialmente lineal, el modelo simple es la elección adecuada.

7. Informe final: hallazgos y recomendaciones

7.1. Jugadores destacados

Aplicando el modelo final a los 40 jugadores, la Tabla 3 recoge los ocho con mayor puntuación, que constituyen la lista prioritaria de seguimiento propuesta a la dirección deportiva.

Tabla 3: Jugadores con mayor probabilidad estimada de alto potencial.

Jugador	Posición	Edad	Pase (%)	Reacción (s)	1v1 (%)	Decisión	Prob.
J31	Extremo	18	92.99	0.51	56.78	7.90	0.95
J21	Delantero	19	76.71	0.47	47.84	8.50	0.90
J13	Defensa	17	78.46	0.49	47.34	8.22	0.90
J28	Extremo	19	80.56	0.58	48.27	8.03	0.87
J03	Extremo	16	83.25	0.56	48.01	7.62	0.79
J30	Delantero	16	81.02	0.60	33.00	8.51	0.77
J33	Centrocampista	19	74.41	0.54	45.46	8.52	0.71
J23	Extremo	19	86.56	0.59	48.08	7.55	0.71

Destacan tres perfiles: J31, extremo de 18 años con la mejor precisión de pase de la muestra (93 %) combinada con una reacción sobresaliente (0,51 s); J21, delantero con el tiempo de reacción más rápido observado (0,47 s) y una toma de decisiones de 8,5, cuyo caso ilustra además el papel del modelo como filtro (no perteneció a la clase de alto potencial retrospectiva, y es precisamente el tipo de desacuerdo entre modelo y etiqueta que merece observación presencial); y J13, defensa de solo 17 años que une reacción (0,49 s) y lectura de juego (8,2), perfil valioso por su margen de desarrollo. La lista aporta además diversidad posicional, con extremos, delanteros, un defensa y un centrocampista.

7.2. Recomendaciones estratégicas

1. **Lista de seguimiento prioritario:** incorporar a los ocho jugadores de la Tabla 3 al programa de observación intensiva, usando la probabilidad del modelo como criterio de priorización de recursos, nunca como decisión automática de fichaje.
2. **Integración con el scouting tradicional:** el modelo es un filtro cuantitativo que debe cruzarse con el criterio de los ojeadores; los desacuerdos entre modelo y ojeador son precisamente los casos que merecen más análisis, no menos.
3. **Ampliación de la base de datos:** extender la anotación hasta los 150–300 jugadores que la curva de aprendizaje señala como punto de rendimiento cercano al máximo ($AUC \approx 0,85$), y reentrenar cada temporada. Con más datos podrán estimarse modelos por posición.
4. **Umbral operativo orientado a sensibilidad:** operar con un umbral en torno a 0,30 mientras exista capacidad de seguimiento, duplicando la detección de talentos frente al umbral estándar.
5. **Refinar las métricas técnicas:** incorporar métricas ajustadas a riesgo (pases progresivos completados) y variables contextuales (nivel del rival, minutos jugados), y revisar la anotación del duelo uno contra uno, cuya señal ha resultado débil en esta muestra.
6. **Gobernanza del dato:** versionar cada modelo, auditar periódicamente sesgos (mes de nacimiento, procedencia, maduración física) y garantizar el cumplimiento del RGPD con menores.

8. Conclusiones

El proyecto demuestra que es viable construir, con medios asumibles para un departamento de scouting, un flujo completo y reproducible que va del vídeo al dato y del dato a la decisión: definición justificada de ocho métricas, limpieza gobernada por reglas explícitas, análisis descriptivo, un modelo predictivo interpretable y una evaluación honesta de su incertidumbre.

El principal hallazgo deportivo es que, en esta muestra, las variables cognitivas y de precisión técnica (toma de decisiones, precisión de pase, regate y velocidad de reacción) anticipan mejor el alto potencial que las de duelo, cuya señal quedó diluida por el ruido muestral. El principal hallazgo metodológico es la cuantificación del valor de los datos: con los 40 jugadores actuales la capacidad discriminante es moderada (AUC de 0,62–0,66), y la curva de aprendizaje demuestra que ampliando la base de datos a 150–300 jugadores se alcanzaría un AUC cercano a 0,85, el máximo que estas métricas permiten. Esa curva

transforma la intuición de que «40 jugadores son pocos» en una recomendación concreta con retorno estimado. El sistema debe entenderse como un prototipo que dirige el trabajo de los ojeadores hacia donde los datos indican que hay más que ver, no como un sustituto del criterio experto.

Referencias

- [1] Lu, Y., Chen, X., and Fu, L. (2018). A review on vision-based analysis of human motion and its applications. *IEEE Transactions on Circuits and Systems for Video Technology*, 28(1):213–227.
- [2] Smith, R. and Johnson, M. (2020). Annotating and labeling sports videos for machine learning: Best practices and tools. *Journal of Sports Technology*, 3(2):45–60.